


ОСНОВЫ In-Context Learning



ИЗБРАННЫЕ ТЕМЫ В ИИ

ДОМАШНЕЕ ЗАДАНИЕ

НЕДЕЛЯ 6

Для зачёта достаточно полностью решить одну задачу. Допустимо и частичное решение двух задач, но в одной должны быть существенные продвижения. Кроме того, можно получить баллы за дополнительные шаги сверх требований.

ЗАДАНИЕ 1. INDUCTION HEADS DIY

Перед решением полезно почитать эти статьи:

1. [на transformer-circuits.pub](#),
2. [на transformer-circuits.pub](#).

Сетап

Двуслойный attention-only трансформер без layernorm с одной головой на каждом слое. Для простоты используем $W_U = W_E^\top$. Словарь состоит из трёх токенов, $V=\{A,B,C\}$, размерность эмбединга $d = 7$, размерность головы аттеншена $d_h=3$. Используем абсолютные позиционные эмбединги, $p(t) = [0,0,\dots,0,t]$, $t \in \{1,2,\dots\}$.

$$W_E = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix} \in \mathbb{R}^{|V| \times d}$$

Например, входная последовательность A, B, A кодируется так:

$$X = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 & 2 \\ 1 & 0 & 0 & 0 & 0 & 0 & 3 \end{pmatrix} \in \mathbb{R}^{T \times d}$$

Твоя задача — придумать такие веса $W_Q^{(\ell)}, W_K^{(\ell)}, W_V^{(\ell)}, W_O^{(\ell)}$ для $\ell \in \{1, 2\}$, что они реализуют induction head circuit. В качестве иллюстрации нужно посчитать вероятность правильного токена на последней позиции в каждой последовательности:

1. A, B, A (ответ: B).
2. C, A, C (ответ: A).
3. B, C, C, A, B (ответ: C).
4. A, A, A, A (ответ: A).

Примечания:

1. $d = 7$ обусловлено следующим: три позиции на кодирование токена, ещё три свободных слота, куда можно записывать новую инфу, и одна для позиционного кодирования.
2. Первая голова должна выполнять копирование предыдущего токена. Чтобы упростить задачу, давай предположим, что каузальная маска в аттеншене *строгая*, то есть так же зануляет значения на главной диагонали ($M_{i,j} = -\infty \iff j \geq i$). Это приведёт к nan в attention map для первого токена, поэтому там нужно будет вручную выставить нулевую строку.
3. Вторая голова обращается от токена x к такому токenu y , что перед ним стоит x .

4. Обязательно прокомментируй смысл каждой матрицы, которая получается по ходу форвада модели для одного из примеров. Например, тебе нужно явно посчитать attention map на первом слое и объяснить, почему он выглядит именно так.
5. Сопроводи решение кодом, который позволит посчитать вероятности правильных токенов для последовательностей выше. Оформить его можно в ноутбуке.

ЗАДАНИЕ 2. FUNCTION VECTORS ACROSS PARTS OF SPEECH

Посмотри статью про function vectors [на arxiv.org](https://arxiv.org).

Возьми за основу этот датасет [c github.com](https://github.com). Он содержит пары синонимов и антонимов для существительных, прилагательных и глаголов. Антонимы имеют метку 1, а синонимы — 0.

1. Собери шесть датасетов (синонимы и антонимы для каждой части речи), каждый элемент которого представляет собой последовательность из десяти примеров и одно слово, для которого необходимо сделать предсказание. Например, для антонимов прилагательных элемент датасета выглядит так:

$$\begin{aligned}x_{i1} &= \text{efficient}, y_{i1} = \text{incompetent}, \\x_{i2} &= \text{dovish}, y_{i2} = \text{hawkish}, \\&\vdots \\x_{i10} &= \text{null}, y_{i10} = \text{valid}, \\x_{iq} &= \text{wild}, y_{iq} = \text{realistic}.\end{aligned}$$

Тогда промпт можно сформировать так:

$$p_i = f"Q:x_{i1}\backslash nA:y_{i1}\backslash n\backslash n \dots Q:x_{i10}\backslash nA:y_{i10}\backslash n\backslash nQ:x_{iq}\backslash nA:"$$

2. Собери активации для любой модели на свой вкус (лучше взять gpt2) методом, описанным в статье, и найди function vectors для всех полученных датасетов. Для удобного сбора активаций стоит воспользоваться библиотекой [transformer_lens](https://transformer-lens.github.io/). При подсчёте вероятностей, учти, что некоторых таргет-слов нет в словаре gpt2, поэтому они будут кодироваться несколькими токенами. Можно отфильтровать датасеты, оставив только те элементы, в которых оба слова в каждом примере кодируются одним токеном.
3. У тебя получилось шесть векторов: $FV_{adj, ant}$, $FV_{adj, syn}$, $FV_{noun, ant}$, Посчитай косинусы углов между ними. Проанализируй.
4. Проверь их схожесть и каузально: например, правда ли, что направление для синонимов прилагательных $FV_{adj, syn}$ увеличивает вероятность для синонимов существительных ("champion" после "hero"), если в промпте нет примеров синонимов? Сделай выводы.
5. Оформи код в репозиторий на гитхабе и опиши все результаты в README.