


Discovering the carry propagation



ИЗБРАННЫЕ ТЕМЫ В ИИ

ДОМАШНЕЕ ЗАДАНИЕ

НЕДЕЛЯ 8



В этом домашнем задании тебе будет предложено обнаружить элементы carry propagation серкута в предобученных моделях. Нужно будет оформить отчёт в рамках поставленного вопроса и описать, какая работа была проделана, что получилось и что нет.

СЕТАП

При сложении чисел величина отдельной цифры может превысить базу системы счисления, и тогда старшая цифра увеличивается на единицу. Это и есть carry propagation:

$$\begin{aligned}
 15 + 28 &= 1 \cdot 10^1 + 5 \cdot 10^0 + 2 \cdot 10^1 + 8 \cdot 10^0 \\
 &= (1 + 2) \cdot 10^1 + (5 + 8) \cdot 10^0 \\
 &= 3 \cdot 10^1 + 13 \cdot 10^0 \\
 &= 3 \cdot 10^1 + 1 \cdot 10^1 + 3 \cdot 10^0 \\
 &\quad \text{поднимаем на 1} \\
 &= (3 + 1) \cdot 10^1 + 3 \cdot 10^0 \\
 &= 43
 \end{aligned}$$

Авторегрессионная модель предсказывает числа ответа слева направо — от старшего порядка к младшему. При генерации каждого токена она должна заранее выполнить carry propagation, иногда для многих токенов подряд. Какой механизм внутри модели позволяет ей это делать? Можно ли его идентифицировать?

Вычисление значимости медиатора

В литературе нередко используется следующий способ вычисления indirect effect; для простоты будем опираться на формулировку из статьи [Arithmetic Without Algorithms](#).

Пусть p и p' — это промпты вида « $a + b =$ », а r и r' — правильные ответы для этих промптов. Прогоним модель на обоих промптах и сохраним активации её элементов в памяти.

Тогда вклад медиатора будет рассчитываться следующим образом:

$$IE = \frac{1}{2} \left(\frac{\mathbb{P}^*(r') - \mathbb{P}(r')}{\mathbb{P}(r')} + \frac{\mathbb{P}(r) - \mathbb{P}^*(r)}{\mathbb{P}^*(r)} \right)$$

где $\mathbb{P}$ — это вероятность ответа при прогоне модели с промптом p , а $\mathbb{P}^*$ означает вероятности, посчитанные в ране с интервенцией: активации для рана на промпте p подменяются активациями, посчитанными на промпте p' (то есть выполняется noising), $p' \rightarrow p$. Вместо вероятностей можно использовать логиты на выходе модели.

ЗАДАНИЕ

Необходимо провести анализ обученного трансформера на предмет того, где локализован и наличествует ли механизм, выделенный под carry propagation.

- Возьми какую-либо предобученную модель, способную выполнять сложение с достаточным качеством, иначе ты будешь изучать шум вместо механизмов. Ты можешь также обучить свой маленький трансформер-калькулятор, это даст больше свободы.
- Обрати внимание на токенизатор: какие-то модели кодируют числа с несколькими цифрами одним токеном (например, GPT-2 так кодирует числа 0–512), а какие-то кодируют числа посимвольно. Это сильно влияет на то, как будет выглядеть механизм.
- Подбери набор данных, способ формирования контрфактуальных промптов и процедуру интервенции, которые позволят тебе выделить отдельные черты этого механизма. Чем будут отличаться noising- и denoising-сценарии?
- Определи, какие компоненты и пути в модели важны для выполнения carry propagation: выбери приемлемую гранулярность анализа (целые Attn/MLP-модули, отдельные головы/нейроны, фичи SAE и тому подобное), затем посчитай важность компонент и путей, которые тебя интересуют. Ты можешь использовать различные методы circuit discovery — выбери тот, который кажется тебе наиболее понятным для анализа.
- Оцени необходимость и достаточность выявленных компонент и путей для выполнения carry propagation. Выяви роль элементов, которые были обнаружены. Проверь, существуют ли какие-то пути (например, компенсаторные), которые участвуют в этой процедуре и которые не удалось обнаружить при первом проходе.
- Сделай выводы: можно ли локализовать серкут, или он распределён по всей модели, или он вовсе отсутствует и carry propagation — это эффект чего-то менее интересного?

Нет необходимости выполнять всю работу по идентификации серкута — важен не конечный результат, а процесс исследования и умение формулировать гипотезы и эксперименты для их проверки. Сфокусируйся на том, чтобы провести подробный анализ и выявить механизмы, которые позволяют модели выдавать правильный ответ, или выяснить, что их не существует (модель может полагаться на эвристики — это тоже хороший результат).

В идеальном случае отключение найденного серкута должно приводить к ошибкам на примерах с carry propagation, но на остальных примерах падения качества быть не должно.

Ты можешь использовать любые библиотеки, которые кажутся тебе необходимыми (за исключением тех, в которых реализован автоматический circuit discovery — используй их только для валидации твоих наблюдений и для оценки того, в правильном ли направлении ты движешься). Для интервенций можно использовать ruvene и transformer-lens.

Вдохновляйся следующими статьями:

- [Arithmetic Without Algorithms: Language Models Solve Math with a Bag of Heuristics](#);
- [A Mechanistic Interpretation of Arithmetic Reasoning in Language Models using Causal Mediation Analysis](#);
- [Interpretability in the Wild: a Circuit for Indirect Object Identification in GPT-2 small](#);
- [Towards Best Practices of Activation Patching in Language Models: Metrics and Methods](#);
- [Interpreting and Improving Large Language Models in Arithmetic Calculation](#);

- [How to use and interpret activation patching](#);
- [Understanding Addition in Transformers](#).

Ты можешь опираться на методологию, описанную в статье Arithmetic Without Algorithms. Основным отличием будет датасет (контрфактуальные пары). По желанию ты можешь работать с другими механизмами и потенциальными серкутами, если сможешь их понятно и подробно охарактеризовать. Обязательно включи это в отчёт вместе с мотивацией.

КРИТЕРИИ ОЦЕНИВАНИЯ

Для получения зачёта необходимо предоставить структурированное описание процедуры поиска carry propagation серкута (или другого выбранного серкута). Необходимо описать модель, подвергаемую анализу, экспериментальный сетап, использующийся для проведения анализа, гипотезы и способ их проверки, а также аккуратно оформить результаты экспериментов (графики, таблицы).

Оформи выводы из каждого эксперимента и анализа целиком. Опиши найденные механизмы и роль выявленных компонентов (если возможно) — что именно они делают для решения задачи?