


Анализ внутренних признаков VLM по слоям



ИЗБРАННЫЕ ТЕМЫ В ИИ

ДОМАШНЕЕ ЗАДАНИЕ

НЕДЕЛЯ 11



Цель

Исследовать, какие визуальные и мультимодальные признаки активируются на разных слоях VLM, и показать это на практике с помощью logit lens или эквивалентного подхода.

В этой задаче нас интересует не Logit Lens как отдельная техника, а вопрос «Какие именно признаки модель начинает “понимать” на разных слоях, а какие признаки не формируются вовсе или формируются нестабильно?».

ЧТО НУЖНО СДЕЛАТЬ

1. Выбрать модели.

Возьми одну мультимодальную модель из списка ниже:

- NanoVLM;
- Qwen2-VL/Qwen2.5-VL;
- LLaVA/LLaVA-OneVision;
- любую другую открытую VLM, если она воспроизводима и помещается в Colab/Kaggle.

2. Определить набор признаков для анализа.

Нужно исследовать минимум три типа признаков. Примеры категорий:

- Цвет.
Примеры: red, blue, green, yellow.
- Форма/объект.
Примеры: circle, square, triangle, car, dog, cup.
- Пространственные отношения.
Примеры: left of, right of, above, below, inside.
- Количество/счёт.
Примеры: one, two, three, many.
- Связка атрибут — объект.
Примеры: red square, blue circle, small dog, large car.

Дополнительно можно взять:

- OCR / текст на изображении.
- Текстуры.
- Действия.
- Части объектов.
- Fine-grained категории.

3. Подготовить данные.

Нужно использовать контролируемый набор примеров, а не только произвольные картинки из интернета.

Допускаются два варианта.

ВАРИАНТ А	Синтетический набор. Сгенерировать простой датасет самостоятельно: • геометрические фигуры, • контролируемые цвета, • позиции объектов, • количество объектов, • пары атрибутов.
ВАРИАНТ В	Готовые датасеты. Можно использовать открытые бенчмарки, но обязательно выделить из них подзадачи под конкретные признаки. <i>Например:</i> • цвета, • счёт, • <i>spatial reasoning</i>, • OCR, • <i>compositional binding</i>.

4. Применить layer-wise-анализ.

Нужно реализовать или адаптировать один из подходов формата logit-lens/layerwise decoding.

ВАЖНО	Анализ должен отвечать не на вопрос «Какие токены самые вероятные вообще?», а на вопрос «Появляется ли целевой признак на данном слое и насколько стабильно?».
-------	--

Минимум, что должно быть измерено

Для некоторых слоёв (например, «из ближе к началу/концу», «каждый четвёртый» и так далее) и выбранных признаков измерь, как меняется:

- probability целевого токена,
- margin между правильным и ближайшим неправильным токеном,
- top-k hit,
- другой воспроизводимый score (можете выбрать самостоятельно).

Примеры

- Для цвета *red* смотреть, входит ли токен *red* в top-10.
- Для отношения *left of* смотреть score у *left*.
- Для количества *three* смотреть позицию токена *three*.
- Для связки атрибут — объект анализировать оба токена или шаблонный ответ.

5. Найти работающие и неработающие признаки.

По итогам экспериментов тебе нужно сформулировать минимум два утверждения.

Примеры допустимых утверждений

- В модели Qwen2-VL признак цвета появляется рано: уже к слоям 6–8 целевой цвет стабильно входит в top-5.
- У LLaVA пространственные отношения формируются позже, чем *object identity*.
- Связка атрибут — объект у NanoVLM нестабильна: модель распознаёт объект и цвет по отдельности, но не удерживает их комбинацию.
- Счёт до 3 работает, но после 4 правильный токен почти никогда не поднимается в top-10.
- OCR-признаки практически не проявляются по слоям в выбранной маленькой модели.

ВАЖНО

Хотя бы одно утверждение должно быть про «неработающий» или слабый признак.