


Изучаем VLA



ИЗБРАННЫЕ ТЕМЫ В ИИ

ДОМАШНЕЕ ЗАДАНИЕ

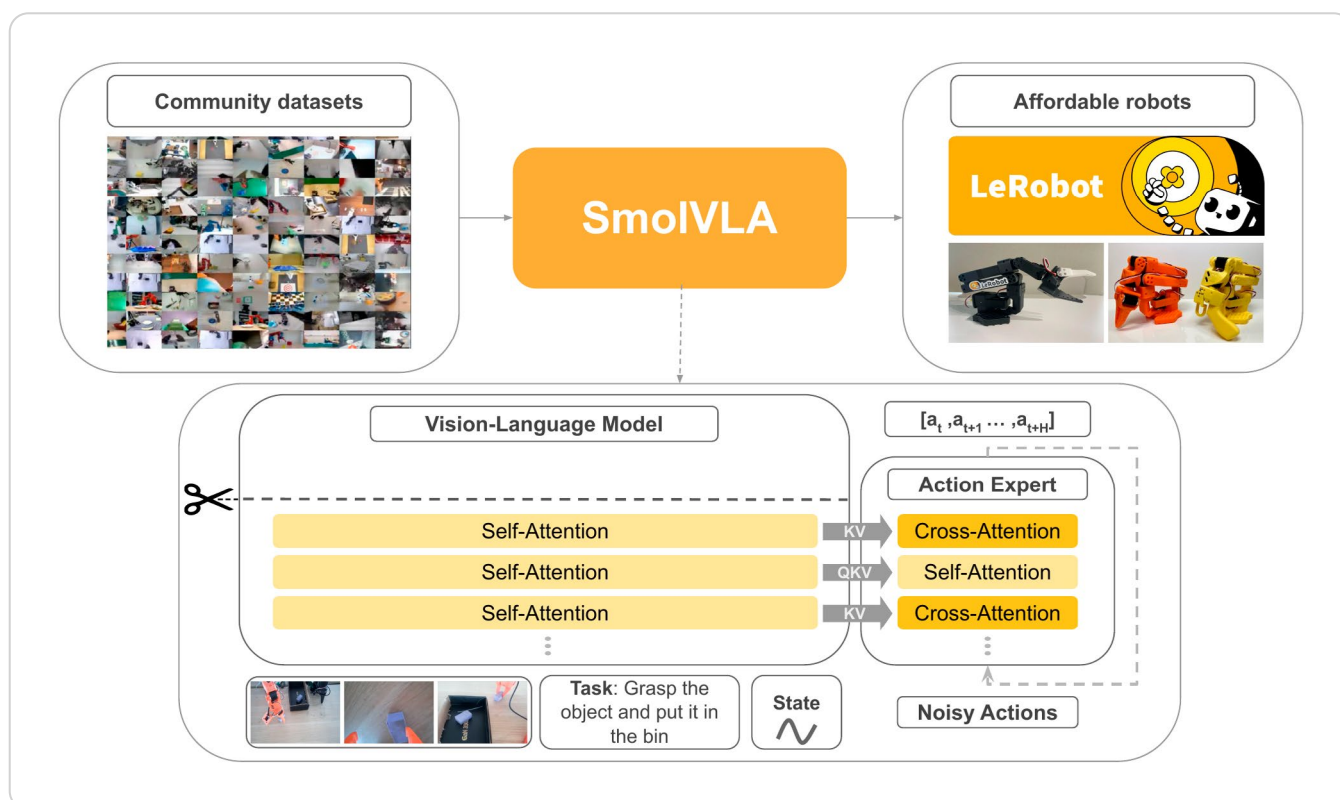
НЕДЕЛЯ 14

На лекции мы обсуждали три способа превратить непрерывное управление роботом в цель обучения: дискретные токены ([RT-2](#)), непрерывная регрессия с чанкингом ([OpenVLA-OFT](#)) и сжатие в частотной области ([FAST](#)). В VLA-литературе основная метрика сравнения методов — closed-loop success rate в симе или на реальном роботе. Но, обучая голову на демонстрациях, первым делом смотрят на offline val loss — это быстрый бесплатный сигнал. Насколько этот shortcut предсказывает closed-loop-поведение? В этом ДЗ вы обучите все три варианта, померите обе метрики и проверите.

СЕТАП

Модели

SmoVLA architecture



[SmoVLA](#) (Shukor et al., 2025): VLM остаётся замороженной (причём отрезается верхняя половина слоёв — ножницы), её фики через interleaved CA + SA идут в action expert, который обучается на community-датасетах роботов и выдаёт чанк действий $[a_t, \dots, a_{t+n}]$. В этом ДЗ мы тоже замораживаем VLM, но заменяем их flow-matching action expert на маленькую голову — **discrete/continuous/chunked**.

- **SmoVLM2-500M-Video-Instruct** ([HuggingFaceTB/SmoVLM2-500M-Video-Instruct](#)) — базовая VLM, не видевшая роботов.
- **SmoVLA** ([lerobot/smolvla_base](#)) — та же VLM-основа плюс action expert, дообученный на роботизированных демонстрациях.

Обе модели **не обучаем** — используем как замороженный бэкбон. Обучаются только маленькие action-головы поверх.

Среда

Meta-World (Yu et al., 2020) — симулятор manipulation (робот Sawyer, 4-DOF action), один из бенчмарков SmolVLA. Демонстрации лежат в [датасете metaworld_mt50 на HuggingFace](#) — 50 задач × 50 эпизодов, не входили в предобучение. В `lerobot.envs.metaworld` уже есть env-wrapper, language instructions и difficulty split — используйте готовое.

Выберите одну задачу из Medium-tier (например, **hammer-v3**, **sweep-into-v3**, **peg-insert-side-v3** или **coffee-push-v3**) — её вы используете во всех частях ДЗ. На Easy-tier SmolVLA paper репортит ~82% success (близко к потолку), на Medium ~42%, на Hard ~45%. Чем дальше от потолка, тем больше пространства, в котором разные варианты головы могут разойтись; поэтому Easy брать не советуем. Сплит: **40 эпизодов train / 10 val** (наше решение; в paper всё используется для тренировки, а eval делается closed-loop в симе).

ЗАДАНИЕ

Для каждой части оформите отчёт в стиле «гипотеза — дизайн эксперимента — результаты — выводы». Процесс исследования важнее конечного результата.

Часть 1. Знает ли VLM действия ещё до роботов?

Вопрос: есть ли action-relevant-информация в замороженной VLM до роботизированного дообучения и на каких слоях она концентрируется?

Эта часть — **offline probing**, без симулятора.

- Прогоните val-изображения из выбранной задачи через **SmolVLM2** с **output_hidden_states=True**. Соберите активации $h^{(\ell)}$ на каждом слое с номером $\ell \in [0, 32]$ (0 — сразу после embeddings, 32 — выход последнего decoder-слоя).
- Для каждого слоя ℓ обучите **линейную регрессию** (не MLP — вас интересует линейно доступная информация): $h^{(\ell)} \rightarrow \hat{a}_t$.
- Повторите для VLM-backbone внутри **SmolVLA**. Важно: в чек-пойнте SmolVLA физически только первые 16 слоёв VLM — верхние 17–32-й удалены ещё на этапе обучения. Пробинг идёт только до слоя $\ell = 16$.
- Метрика: R^2 как функция номера слоя, один график. Кривая SmolVLM2 идёт до слоя 32, кривая SmolVLA — до 16-го.
- **Интерпретация.** Проанализируйте кривую и зафиксируйте номер лучшего слоя $\ell^* = \arg \max_{\ell} R^2(\ell)$ на SmolVLM2 — этот слой используется как источник признаков во всех остальных частях.

Часть 2. Три способа говорить на языке действий: offline vs closed-loop

Вопрос: какое представление действий лучше работает в закрытом цикле и является ли offline val loss надёжным shortcut'ом для этого вывода?

Нормализация. Обучайте голову в нормализованном action-пространстве (**mean-std z-score** по train-статистике, как у SmolVLA). При rollout'e денормализуйте обратно и clip в $[-1, 1]$ — Meta-World принимает действия именно в этом диапазоне.

Обучите **три отдельные action-головы** поверх признаков $h^{(e*)}$ (с лучшего по probing слоя из части 1) из замороженной SmolVLM2. Бэкбон и данные одинаковые, меняются только output head и loss. Архитектура головы — на ваш выбор, но **идентичная** для всех трёх вариантов.

Вариант А. Discrete tokens (RT-2 style)

Дискретизируйте каждую координату действия в $K = 256$ равных бинов по train-статистике. Per-dim softmax, CE loss. На инференсе — **argmax** → **центр бина** (стандартный приём, когда дискретный выход надо вернуть в непрерывный).

Вариант В. Continuous regression (OpenVLA-OFT style, 1 step)

Прямая регрессия $h^{(e)} \rightarrow \hat{a}_t$ с L1 loss.

Вариант С. Continuous chunks (OFT, H steps)

Регрессия $h \rightarrow [a_t, \dots, a_{t+H;-1}]$ за один forward. L1. Возьмите H в диапазоне 10–50 (для справки: SmolVLA paper использует $H = 50$ как дефолт). Обоснуйте свой выбор.

На инференсе используйте протокол SmolVLA paper для симуляции: **predict chunk, execute первое действие, re-sample observation, предсказать заново**. То есть каждый env-шаг делает один forward VLM + head — честное сравнение с вариантами А и В.

Offline-метрика (shortcut)

MSE на val demonstrations в нормализованном пространстве действий. В VLA-литературе эту метрику почти не используют как основную — она появляется как training-time-сигнал (валидация сходимости, early stopping). Но раз уж вы всё равно получили числа, приглядитесь к ним: попробуйте *предсказать* по ним, кто выиграет в closed-loop. Для варианта С сравнивайте только a_t — первый шаг чанка.

Closed-loop-эксперимент (основная метрика)

Для каждого варианта прогоните rollout в Meta-World:

- **≥ 10 эпизодов** (желательно ≥ 20 если GPU позволяет) на одних и тех же начальных условиях для всех трёх вариантов (фиксируйте env seed при reset);
- горизонт эпизода — до 500 шагов (дефолт Meta-World), с early termination по success. На Colab можно урезать до 300 — если упираетесь в бюджет, обоснуйте;
- метрика: **success rate** — доля эпизодов, где задача полностью выполнена в соответствии с критерием Meta-World (binary, как в SmolVLA paper). При $N = 10 - 20$ разница в 10–15 pp может быть в пределах шума — учитывайте это при сравнении. Если разницу «не видно», это валидный результат — напишите об этом честно.

Калибровочная проверка (перед rollout'ом). Убедитесь, что все три головы сошлись на train (train MSE близка к floor'у для каждой). Если одна не сошлась, исправляйте обучение, иначе вы сравниваете не представления, а качество оптимизации.

Таблица: [вариант × offline val MSE × success rate].

Интерпретация

- Даёт ли offline val MSE тот же ответ про лучший вариант, что и closed-loop SR? Если нет, стоит ли вообще смотреть на offline MSE при разработке действующей политики?
- Посмотрите на несколько провалившихся эпизодов (рендерите кадры или записывайте видео). В какой момент политика сходит с разумной траектории и почему именно там?
- Назовите один результат, который вас удивил, и почему.

Часть 3. Открытое исследование

В частях 1 и 2 вы построили достаточно инструментов — два backbone, три головы, sim-среду, — чтобы задавать свои вопросы про VLA. Часть 3 — ваше исследование.

Сформулируйте **свой** вопрос и гипотезу, исходя из того, что вы увидели в результатах частей 1–2 или что вам показалось интересным в SmolVLA/лекции. Проверьте экспериментами. Отчёт в формате: вопрос → гипотеза → дизайн → результаты → выводы.

Бонус. FAST-like tokenizer

Реализуйте упрощённую версию FAST: возьмите chunk, примените 1D DCT (Discrete Cosine Transform) по времени, дискретизируйте каждый DCT-коэффициент. Per-coef CE loss. Сравните с вариантами A/B/C из части 2 в closed-loop. Действительно ли частотная область информативнее временной?

КРИТЕРИИ ОЦЕНИВАНИЯ

Что сдать: ноутбук (.ipynb) или репозиторий с кодом, PDF/Markdown-отчёт.

	Баллы	Что оценивается
Часть 1	1	Работающий layer-wise probe, две кривые (VLM и VLA), выбор номера слоя ℓ^* с описанием формы кривой
Часть 2	5	Три обученных варианта с идентичным бюджетом + калибровочная проверка. Таблица offline MSE и closed-loop success rate. Анализ расхождения между двумя метриками
Часть 3	4	Минимум одна гипотеза с экспериментами, способными её подтвердить или опровергнуть, честная интерпретация
Бонус	+1	За реализацию FAST-like-токенайзера и честное сравнение с A/B/C

Статьи:

- [RT-2](#) — дискретизация действий в 256 бинов;
- [OpenVLA-OFT](#) — непрерывная регрессия + чанкинг вместо дискретных токенов;
- [FAST](#) — токенизация действий в частотной области (DCT + BPE);
- [SmolVLA](#) — small VLA, eval на Meta-World и LIBERO;
- [Meta-World](#) — Yu et al. (2020), симулятор.